

Cuestionario de Preguntas Abiertas

Unidad: Apache Cassandra (Base de Datos NoSQL)

Nombre del estudiante: Ruiz Carreño Adrian Alejandro

Carrera: **Ing. En Sistemas e Informatica**

Fecha: 18/06/26

Puntaje: ____ / 20 puntos

Instrucciones:

Responda de manera clara y fundamentada cada una de las siguientes preguntas. Puede utilizar ejemplos cuando sea necesario para complementar su respuesta.

Tema 1: Introducción a las características de Apache Cassandra

1.

¿Qué es Apache Cassandra y cuál es su principal propósito dentro de las bases de datos NoSQL?

R. Apache Cassandra es un sistema de gestión de bases de datos NoSQL distribuido, de código abierto, diseñado para manejar volúmenes masivos de datos; Su principal propósito es ofrecer una alta disponibilidad, escalabilidad horizontal lineal y un rendimiento extremadamente rápido

2.

Explique al menos cinco características que diferencian a Apache Cassandra de una base de datos relacional tradicional.

- Modelo de datos: Cassandra utiliza un modelo basado en familias de columnas (column-family) sin un esquema rígido en sus inicios, a diferencia de las tablas con esquemas estrictos (filas y columnas fijas) de SQL.
- Arquitectura: Es un sistema distribuido Peer-to-Peer (todos los nodos son iguales), mientras que las bases de datos relacionales suelen seguir un modelo maestro-esclavo.
- Escalabilidad: Cassandra escala horizontalmente de manera nativa (añadiendo más servidores), mientras que las bases relacionales suelen escalar verticalmente (mejorando el hardware de un servidor principal).
- Ausencia de JOINs: A diferencia de SQL, Cassandra no soporta operaciones de cruce de tablas (JOIN). Los datos se desnormalizan e insertan pensando en cómo van a ser leídos.
- Consistencia ajustable (Tunable Consistency): Permite al desarrollador decidir por cada lectura/escritura si prefiere consistencia absoluta (esperar a que todos los nodos se sincronicen) o menor latencia (alta disponibilidad).

3.

¿Por qué Apache Cassandra es considerada una base de datos altamente escalable? Justifique su respuesta.

Es altamente escalable debido a su arquitectura distribuida donde los datos se dividen automáticamente (particionamiento) entre todos los nodos del clúster mediante un hash.

4.

¿Qué significa que Cassandra tenga una arquitectura distribuida y cuáles son sus ventajas para las grandes organizaciones?

Significa que la base de datos no reside en un solo equipo, sino que funciona como una red de múltiples servidores interconectados operando como uno solo. Sus ventajas para grandes organizaciones incluyen la recuperación ante desastres.

5.

Explique el concepto de tolerancia a fallos en Cassandra y cómo contribuye a la disponibilidad de la información.

La tolerancia a fallos se logra mediante la replicación. Cassandra guarda copias (réplicas) de los mismos datos en distintos nodos de forma automática (según un factor de replicación definido, ej. 3 réplicas). Si un servidor se apaga, se daña o pierde conexión, el clúster sigue funcionando y responde a las consultas de los usuarios extrayendo la información desde uno de los otros nodos que contienen la réplica.

6.

¿Cuáles son las principales aplicaciones o casos de uso donde Apache Cassandra resulta una mejor alternativa que una base de datos SQL?

- Sistemas de Internet de las Cosas (IoT) y registro de métricas de sensores (series de tiempo).
- Aplicaciones de mensajería instantánea y redes sociales.
- Sistemas de recomendación y personalización en tiempo real.
- Motores de detección de fraudes en transacciones financieras.
- Sistemas de logging y análisis del comportamiento de usuarios en la web.

7.

Describa cómo funciona el modelo Peer-to-Peer (P2P) en Cassandra y por qué elimina el punto único de fallo.

En el modelo P2P, todos los nodos del clúster tienen exactamente el mismo rol y responsabilidades. No hay un "nodo maestro" que coordine las transacciones y "nodos esclavos" que solo lean. Cualquier nodo puede recibir solicitudes de lectura o escritura desde la aplicación cliente. Si un nodo falla, el sistema no se paraliza (elimina el punto único de fallo), ya que la aplicación simplemente se comunica con otro nodo activo disponible.

Tema 2: Instalación de Apache Cassandra

8.

¿Qué requisitos de software y hardware son necesarios para instalar Apache Cassandra en un equipo?

- **Hardware:** Se recomienda procesadores multinúcleo modernos, al menos 8 GB de RAM (exclusivos para la base de datos en entornos de producción) y discos de estado sólido (SSD) para un rendimiento óptimo de lectura/escritura.
- **Software:** Un sistema operativo, preferiblemente distribuciones de Linux (Ubuntu, CentOS, etc.) para producción. Requiere tener instalado Java Development Kit (JDK 8 u 11) y Python 3.6+ para el uso de la consola interactiva.

9.

Explique la importancia de Java (JDK) dentro de la instalación y funcionamiento de Apache Cassandra.

Apache Cassandra es una aplicación escrita íntegramente en el lenguaje de programación Java. Por lo tanto, para poder ejecutarse, depende del entorno de ejecución de Java (JVM - Java Virtual Machine). El JDK proporciona las bibliotecas y herramientas necesarias para que el código de Cassandra sea interpretado y gestionado por el sistema operativo.

10.

Describa paso a paso el proceso general para instalar Apache Cassandra en un sistema operativo Windows o Linux.

1. **Instalar requisitos:** Descargar e instalar Java (JDK) y Python en el sistema.
2. **Configurar variables de entorno:** Definir `JAVA_HOME` apuntando al directorio de instalación de JDK.
3. **Descargar Cassandra:** Bajar el archivo comprimido (tarball) desde la página oficial de Apache.
4. **Extraer:** Descomprimir el archivo en el directorio deseado (ej. `/opt/cassandra`).
5. **Iniciar el servicio:** Navegar hasta el directorio `bin` y ejecutar el comando `./cassandra` (o configurarlo como un servicio de `systemd` para que corra en segundo plano).

11.

¿Qué es el archivo **cassandra.yaml** y cuál es su función dentro de la configuración del sistema?

Es el archivo de configuración principal de Cassandra. Su función es permitir al administrador ajustar los parámetros clave del nodo y del clúster. Allí se define el nombre del clúster (`cluster_name`), la dirección IP por la que el nodo se comunicará con otros (`listen_address`), el directorio donde se guardarán los datos físicos (`data_file_directories`) y la lista de nodos semilla (`seeds`) para descubrir la red.

12.

¿Cómo se verifica que Apache Cassandra ha sido instalado correctamente en un equipo?

Se puede verificar mediante la herramienta `nodetool`. Al ejecutar el comando `nodetool status` en la terminal, se mostrará una lista de los nodos del clúster. Si la instalación y arranque fueron exitosos, el estado del nodo mostrará las letras UN (Up and Normal), indicando que está encendido y funcionando correctamente.

13.

Explique la función de la herramienta **CQLSH** y mencione algunos comandos básicos

que pueden ejecutarse desde ella.

CQLSH (Cassandra Query Language Shell) es la interfaz de línea de comandos interactiva escrita en Python que permite a los usuarios comunicarse con la base de datos utilizando el lenguaje CQL (muy similar a SQL).

Comandos básicos:

- `DESCRIBE KEYSPACES;` (Lista las bases de datos).
- `USE nombre_keyspace;` (Selecciona un espacio de trabajo).
- `DESCRIBE TABLES;` (Lista las tablas).
- `SELECT * FROM tabla;` (Consulta datos).
- `EXIT;` (Cierra la consola).

Tema 3: Trabajo con Columnas en Cassandra

14.

¿Qué es una columna dentro de Cassandra y qué información almacena?

En la arquitectura subyacente, una columna es la unidad de almacenamiento más pequeña en Cassandra. A diferencia de las celdas en SQL, una columna en Cassandra es una estructura de datos que contiene tres elementos: un nombre (clave), un valor, y un timestamp (marca de tiempo que ayuda a resolver conflictos de sobreescritura de datos).

15.

Explique la diferencia entre una columna y una fila dentro del modelo de datos de Cassandra.

Una fila (Row) es una colección estructurada de columnas asociadas a una única Clave de Partición (Partition Key). Mientras que la fila agrupa los datos, la columna es cada uno de los pares clave-valor individuales dentro de esa fila. Múltiples columnas construyen el registro completo de una fila.

16.

¿Qué es una familia de columnas (Column Family) y cómo se relaciona con las tablas utilizadas en Cassandra?

Una Familia de Columnas era la terminología original usada en las versiones antiguas de Cassandra y en Thrift API. Representa un contenedor de múltiples filas (algo similar a una tabla en bases de datos relacionales). Con la llegada de CQL (Cassandra Query Language), el término "Familia de Columnas" fue reemplazado conceptualmente por "Tabla" (Table) para hacerlo más familiar a los desarrolladores con experiencia en SQL.

17.

Describa el procedimiento para crear una tabla en Cassandra indicando el uso de columnas y claves primarias.

Para crear una tabla se utiliza el comando `CREATE TABLE` en CQL, especificando el nombre de la tabla, los nombres de las columnas con sus tipos de datos (como texto, entero, UUID) y estableciendo obligatoriamente la Clave Primaria (PRIMARY KEY).

Ejemplo conceptual:

```
CREATE TABLE usuarios ( id_usuario UUID, nombre TEXT, edad INT, PRIMARY KEY (id_usuario) );
```

18.

Explique la importancia de la Primary Key en Cassandra y cómo influye en la organización de los datos.

La Primary Key (Clave Primaria) es fundamental porque dicta cómo y dónde se almacenan físicamente los datos en el clúster. La Primary Key se compone de dos partes:

- **Partition Key (Clave de Partición):** Obligatoria. Determina en qué nodo físico se almacenará la fila usando un algoritmo hash.
- **Clustering Key (Clave de Agrupamiento):** Opcional. Determina el orden de clasificación física (ascendente o descendente) de los datos dentro de esa partición específica, lo cual es vital para hacer consultas eficientes por rangos.

19.

¿Cómo se insertan datos en una tabla utilizando el lenguaje CQL? Explique el procedimiento y mencione la estructura general de la instrucción.

Se insertan utilizando el comando INSERT INTO. A diferencia de SQL, en Cassandra un INSERT actuará como un "Upsert": si la clave primaria no existe, crea el registro; si ya existe, lo sobrescribe utilizando el timestamp más reciente.

Estructura general:

```
INSERT INTO nombre_tabla (columna1, columna2, columna3) VALUES (valor1, valor2, valor3);
```

20.

Imagine que una empresa desea almacenar millones de registros de sensores IoT que generan información continuamente. Explique por qué Apache Cassandra sería una buena alternativa y cómo organizaría las columnas para almacenar dichos datos eficientemente.

Por qué usar Cassandra: La arquitectura de Cassandra está altamente optimizada para escrituras masivas en disco, por lo que puede recibir millones de eventos por segundo de los sensores sin cuellos de botella.

Además, puede escalar para almacenar estos inmensos volúmenes históricos simplemente añadiendo nodos.

Organización de las columnas: Se utilizaría un modelo de modelado para series de tiempo (Time-Series Data).

- **Partition Key:** Usaría el `id_sensor` combinado con un elemento temporal (como `mes_año`) para evitar particiones excesivamente grandes e inmanejables.
- **Clustering Key:** Usaría el `timestamp` (marca de tiempo exacta del evento) ordenado de forma **descendente** (`ORDER BY timestamp DESC`).
- **Otras columnas:** Variables como `temperatura`, `humedad`, `bateria`, etc. De esta manera, los datos de un sensor específico durante un mes se guardan en el mismo nodo, ordenados desde la lectura más reciente a la más antigua, permitiendo consultas instantáneas como "Dime las últimas 10 métricas del sensor X".

Rúbrica de Evaluación (20 puntos)

Criterio	Puntaje
Dominio conceptual sobre Apache Cassandra	5 puntos
Comprensión de la instalación y configuración	5 puntos

Conocimiento sobre el trabajo con columnas y tablas	5 puntos
Capacidad de análisis, argumentación y uso de ejemplos	5 puntos
Total	20 puntos

Este cuestionario está diseñado para un **nivel universitario**, promoviendo el análisis, la comprensión de conceptos y la aplicación práctica de **Apache Cassandra**, desde sus características fundamentales hasta la instalación y el manejo de columnas mediante **CQL (Cassandra Query Language)**.